光模块公司财报问答知识库

12 家 A 股光模块/光通信公司 × (2025 年度报告 + 2026 半年度报告) = 24 份 PDF · 11543 个文本块 · 向量 + BM25 混合检索 · 答案逐条带公司/报告/页码出处 · 全程不调用大模型 API

11543	24	10 / 10	12 / 12
文本块（年报 6604 / 半年报 4939）	份财报，全部取自巨潮资讯网	评测题作答正确（1 题首句不理想）	跨公司题逐家取到数并核对

1 流水线

① 语料
巨潮资讯网 24 份 PDF → PyMuPDF 逐页抽取 → 按章节/表格边界切块，11543 块，每块带公司·报告·章节·页码

② 双路索引
Qwen3-Embedding-0.6B → Chroma（cosine）
jieba + BM25Okapi → bm25.pkl

③ 召回
RRF（k=60）融合 + 公司/报告期元数据预过滤
另备表头词定位通道（跨公司/定性题用）

④ 答案层
摘句打分 / 显式计算 / 拒答守卫
每条答案带页码出处

2 评测结果（10 题，5 类）

题	类型	问题要点	三路召回最好	最终作答
Q1	单公司·精确数字	新易盛 2026H1 营业收入	#3	对，首条即目标行
Q2	单公司·原因/语义	中际旭创收入大增的原因	未命中	对
Q3	表格 + 计算	太辰光营业成本与毛利率	#1	对，算出 34.81%
Q4	★单位陷阱	德科立 2026H1 营业收入	#1	对（545,069.47 千元）
Q5	★跨公司·增速排名	收入同比增速前三	3/12 家	对，12/12 家取到数
Q6	★跨公司·规模排名	收入规模前三	5/12 家	对，12/12 家取到数
Q7	年报 vs 半年报	光迅科技 2025 全年营业收入	未命中	对（119.29 亿）
Q8	定性·双主业	剑桥科技的主要业务	未命中	对，但首句不理想
Q9	★数字完整性陷阱	新易盛 2025 全年营业收入	#1	对（248.42 亿）
Q10	★应拒答 / 幻觉测试	宁德时代 2026H1 营业收入	—	拒答正确

3 核心结论：跨公司取数，单次检索不够

把 12 家公司的财报放进同一个向量库，**稠密检索并不会自动替你收齐**。 问「增速最快的前三家」时，向量路只覆盖 4/12 家、BM25 路 4/12 家、融合后反而掉到 3/12 家 —— 融合在这里是负贡献：各家写各家的叙述，没有哪一块文本「长得像」一个跨文档的排名答案。 改走两条**定位通道**后覆盖到 12/12：跨公司排名题对 12 家**逐公司枚举**， 用表头词 `主要会计数据` 定位同一张可比口径的表，再解析排序、逐家与金标对账； 定性题用标题词 `主营业务` 定位章节，绕开与「公司/业务」词面高度重合的同业竞争段落。

数字取全之后，两个真实陷阱才会露出来：德科立整份报告用「千元」而其余 11 家用「元」， 不换算它会从垫底窜到规模第一；新易盛母公司营业收入（267.11 亿）比合并数（209.10 亿）还大， 不截断母公司列就会答错。

4 已知短板（如实记）

- **Q8 首句不理想**：正确句排在第 2 条，第 1 条是「行业情况未发生重大变化」这类泛泛句， 打分公式里短句占便宜。
- **拒答靠启发式**：按公司名后缀（公司/集团/科技/时代…）识别库外实体。 英文名 `Coherent` 或简称「宁王」会漏判，届时可能拿库里某家的数字作答。
- **Q9 是绕开不是堵住**：引用的是原文里完整写出的叙述句；若某口径只存在于被 PDF 切断的表格里（`24,841,854,840.22`），仍会踩到。
- **答案层不生成、只摘录**：好处是每个数字都能翻回页码核对， 代价是需要归纳、改写的问题答不了。

逐题记录（召回了哪些块 / 答对没有 / 错在哪 / 怎么修）见 `eval/report.md`； 问答界面截图见 `shots/`； 复现步骤见 `README.md`。 财报 PDF 来自巨潮资讯网公开披露文件，仅作技术验证用。