作业3 · 方向A — 复核对照表

代码仓库（公开）：https://github.com/jinyanxiaonku6/earnings-rag

这次交的是什么：把 12 家 A 股光模块 / 光通信公司的 **2025 年度报告 + 2026 半年度报告**（共 **24 份**，全部取自巨潮资讯网公开披露文件）做成一个能问答的本地知识库 —— **向量检索 + BM25 混合召回（RRF）**，答案从原文摘句、逐条带「公司 / 报告 / 章节 / 页码」出处。 10 道评测题（含 2 道跨公司全景题、1 道应拒答题），10/10 作答正确，召回与作答分开评价。

> 抓取、抽文本、切块、向量化、BM25、融合、作答、评测的**全部实现都在本仓库内**（`scripts/` 8 个文件 + `eval/` 5 个文件 + `data/manifest.json`，初始提交 fa940fe，共 24 个文件）。 作业1 的前端源码仓与本作业无关，本作业没有复用它的任何代码。

一、按复核意见逐条对应

#	复核要求	落地材料（仓库内路径）	在线直链
1	至少 10 家公司**官方完整报告**的清单与出处	`data/manifest.json` —— 12 家 × 2 期 = 24 条，每条含公司名 / 代码 / 报告期 / 公告标题 / 文件名 / **巨潮资讯网原始 URL**	manifest.json
2	报告本体（可复现）	`scripts/fetch_reports.py` 按 manifest 逐份下载，已下载自动跳过；24 份 PDF 可一键重建（PDF 体积大未入库）	fetch_reports.py
3	**向量检索**实现	`scripts/build_index.py`：Qwen3-Embedding-0.6B（1024 维，`max_seq_length=1024`）→ Chroma，cosine	build_index.py
4	**BM25** 实现	`scripts/build_index.py`：jieba `cut_for_search` 分词 + `BM25Okapi`，索引落盘 `data/bm25.pkl`	同上
5	混合（融合）实现	`scripts/search.py`：RRF `k=60`，两路各取 30 个候选；另含元数据预过滤与条目定位	search.py
6	切块与元数据（页码/章节）	`scripts/chunk.py`：按章节/表格边界切，块带 company / report / section / page	chunk.py
7	10 道题（≥2 道跨公司全景题）	`eval/questions.json` —— Q1–Q10，5 类：精确数字 / 语义 / 表格计算 / **跨公司全景（Q5、Q6）** / 应拒答（Q10）；含金标公司+报告+页码	questions.json
8	逐题**真实答案**与检索证据	`eval/results.json` —— 原始运行输出，10 条 record，每条含 `question / gt / modes`（三路召回条目）/ `hits_for_answer` / `answer_extractive`	results.json
9	逐题**判定**（对/错/错在哪/怎么修）	`eval/report.md`（1068 行）：每题「召回情况 + 判定 + 错在哪 + 怎么修 + 遗留」	report.md
10	**实际运行输出**	`eval/run_2026-10-12.txt`（本次复跑 stdout，10 题 × 3 路 × 命中/覆盖）；`eval/results.json` 即该次运行的落盘结果，**与 2026-09-29 首次评测逐字节一致**（10 题召回名次、覆盖家数全部复现）	run_2026-10-12.txt
11	复现步骤	`README.md`「怎么跑」5 步：装依赖 → 抓报告 → 建索引 → 提问 → 起网页	README.md
12	一页结论 / 问答截图（沿用已有）	`一页结论.pdf`（源 `一页结论.html`）、`shots/` 4 张（`scripts/shots.py` 可重跑）	一页结论.pdf · shots/

二、召回命中 与 答题正确 是分开评价的

对应第三课 61–63（召回评估）与 90–92（生成/作答评估）、163（实验记录）三处要求，本项目把两层指标 拆开、并列展示，**不合并成一个总分**：

召回层（`eval/report.md` 的「汇总」表，只记名次/覆盖数，与答案对错无关）

- 单公司题记 **金标块名次**：命中判定 = 检索结果里出现「金标公司 + 金标报告 + 金标页 ±1 页」的块；
- 跨公司全景题记 **覆盖家数**（12 家中召回了几家）；
- 五列对照：`向量 / BM25 / 混合 / 混合(关掉元数据预过滤) / 全景枚举`。
- 结论：单次检索在跨公司题上只覆盖 **3–5 / 12 家**（三路都一样，融合有时是负贡献）； 换成「逐公司枚举 + `$contains="主要会计数据"` 表头词定位」后 **12/12**。

作答层（每题「判定」段）

- 写清「答对 / 答错」、答案数值、以及**证据出处**（公司+报告+页码）；

- 答错或答得不理想的照写不删：**Q8 首句不理想**（正确句排在第 2 条）、 **拒答守卫是启发式**（英文名/简称会漏判）、**Q9 是绕开不是堵住**， 三条都进了 README「已知短板」。

两层不同步的例子（正说明必须分开看）：Q2 / Q7 / Q8 三路混合检索**都没命中金标块**， 但最终作答仍**答对** —— 因为答案层走了「逐公司枚举 / 表头词定位 / 摘句打分」另一条路。 若把召回和作答揉成一个分数，这三题既算不清也对不上账。

三、语料清单与出处（12 家 × 2 期 = 24 份）

`data/manifest.json` 全量展开。「披露日期」取自巨潮资讯网原文链接路径。 **2026-10-12 对 24 条 URL 逐条做了 HTTP HEAD 校验：24/24 返回 200**（脚本：`curl -I` 逐条检查）。

公司	代码	报告	披露日期	原始出处
中际旭创	300308	2025年年度报告	2026-03-31	巨潮原文
中际旭创	300308	2026年半年度报告	2026-08-22	巨潮原文
新易盛	300502	2025年年度报告	2026-04-24	巨潮原文
新易盛	300502	2026年半年度报告	2026-08-25	巨潮原文
天孚通信	300394	2025年年度报告	2026-04-08	巨潮原文
天孚通信	300394	2026年半年度报告	2026-08-19	巨潮原文
光迅科技	002281	2025年年度报告	2026-04-23	巨潮原文
光迅科技	002281	2026年半年度报告	2026-08-20	巨潮原文
博创科技	300548	2025年年度报告	2026-03-28	巨潮原文
博创科技	300548	2026年半年度报告	2026-08-22	巨潮原文
太辰光	300570	2025年年度报告	2026-03-31	巨潮原文
太辰光	300570	2026年半年度报告	2026-08-15	巨潮原文
剑桥科技	603083	2025年年度报告	2026-03-31	巨潮原文
剑桥科技	603083	2026年半年度报告	2026-08-25	巨潮原文
华工科技	000988	2025年年度报告	2026-03-26	巨潮原文
华工科技	000988	2026年半年度报告	2026-08-27	巨潮原文
源杰科技	688498	2025年年度报告	2026-03-25	巨潮原文
源杰科技	688498	2026年半年度报告	2026-08-29	巨潮原文
仕佳光子	688313	2025年年度报告	2026-04-18	巨潮原文
仕佳光子	688313	2026年半年度报告	2026-08-01	巨潮原文
德科立	688205	2025年年度报告	2026-03-31	巨潮原文
德科立	688205	2026年半年度报告	2026-08-18	巨潮原文
联特科技	301205	2025年年度报告	2026-04-29	巨潮原文
联特科技	301205	2026年半年度报告	2026-08-28	巨潮原文

单位口径提醒：**德科立（688205）整份报告以「千元」列示**，其余 11 家为「元」。这条已写进作答层， 否则该题会错一个量级（见 `eval/report.md` Q4）。

四、怎么复跑出以上材料

```
python -m venv .venv && .venv/Scripts/pip install -r requirements.txt

python scripts/fetch_reports.py                                  # 按 manifest 抓 24 份 PDF

python scripts/extract.py && python scripts/chunk.py && python scripts/build_index.py

python eval/run_eval.py --k 8      # → eval/results.json（10 题三路召回 + 作答）

python eval/make_report.py         # → eval/report.md（逐题记录）
```

`python scripts/ask.py "中际旭创2026年上半年营业收入是多少？"`

`python scripts/app.py 8848          # 网页版 → http://127.0.0.1:8848/?q=...`

本次复跑输出见 `eval/run_2026-10-12.txt`；作答不调用任何外部 API（`.env` 未配置，也不在仓库里）。